

## Tarea 3: Asignación de Microservicios en Infraestructura de Servidores

(IIP314W) Optimización Aplicada a Negocios

---

Profesor: Ing. Rodrigo Trigo Vilches

Ayudante: Lic. Vicente Ramírez Almonacid

Año 2026 - Trimestre 1 | Universidad del Desarrollo

---

### Contexto: Despliegue de Microservicios en la Nube

Una empresa de tecnología necesita desplegar su arquitectura de microservicios en una flota de servidores físicos propios. La empresa cuenta con **S servidores disponibles**, cada uno con una capacidad de cómputo limitada y un costo fijo de activación (energía, licencias, mantenimiento, etc.). No todos los servidores necesitan estar activos: el objetivo es activar la menor cantidad posible, minimizando así los costos de infraestructura.

La empresa tiene **M microservicios** que deben ser instalados, cada uno con un requerimiento de capacidad conocido. Sin embargo, la arquitectura impone restricciones operacionales importantes:

- Los microservicios **M1, M2 y M3** son réplicas del mismo servicio crítico. Para garantizar **alta disponibilidad**, deben instalarse en servidores **distintos**, de modo que si un servidor falla, los otros dos siguen operando.
- Los microservicios **M4 y M\_M** (el último microservicio) tienen una dependencia de baja latencia y, por instrucción del cliente, deben instalarse en el **mismo servidor**.

El desafío de la empresa es determinar qué servidores activar y cómo asignar cada microservicio, de modo que se minimice el costo total de activación respetando todas las restricciones.

---

### Conjuntos

| Símbolo | Descripción                                            |
|---------|--------------------------------------------------------|
| $S$     | Conjunto de servidores, $s \in \{1, 2, \dots, S\}$     |
| $M$     | Conjunto de microservicios, $m \in \{1, 2, \dots, M\}$ |

---

## Parámetros

| Parámetro | Descripción                               | Unidad   |
|-----------|-------------------------------------------|----------|
| $C_s$     | Capacidad máxima del servidores           | unidades |
| $F_s$     | Costo fijo de activar el servidores       | \$       |
| $K_m$     | Capacidad requerida por el microserviciom | unidades |

## Desarrollo

### Parte A: Formulación del Modelo

Formule un **modelo de programación lineal entera mixta (MILP)** que permita minimizar el costo total de activación de servidores, considerando:

1. Cada microservicio debe instalarse en **exactamente un** servidor.
2. La suma de capacidades de los microservicios asignados a un servidor no puede superar su capacidad  $C_s$ .
3. Un servidor solo puede recibir microservicios si está **activado**.
4. Los microservicios M1, M2 y M3 deben instalarse en **servidores distintos** entre sí.
5. Los microservicios M4 y M\_M (el último microservicio) deben instalarse en el **mismo servidor**.

En su formulación debe incluir:

- **Variables de decisión:** defínalas claramente, indicando dominio y significado.
- **Función objetivo:** minimizar el costo total de activación.
- **Restricciones:** una por cada condición descrita, con su nombre o descripción al lado.

**Nota:** preste atención a la linealidad de las restricciones. Si alguna condición no es lineal directamente, justifique cómo la lineariza.

### Parte B: Implementación Computacional

Implemente el modelo formulado en **gurobipy** y realice experimentos computacionales con instancias de gran escala.

**Generación de Instancias** Genere instancias aleatorias con al menos **S = 5.000 servidores** y **M = 10.000 microservicios** (puede usar valores mayores a elección). Los parámetros se generan de la siguiente forma:

| Parámetro | Distribución sugerida      |
|-----------|----------------------------|
| $C_s$     | Uniforme entre 50 y 200    |
| $F_s$     | Uniforme entre 100 y 1.000 |
| $K_m$     | Uniforme entre 1 y 20      |

Use una **semilla fija** igual al rut de uno de los integrantes del grupo.

**Preguntas a Responder** Con la instancia generada, responda:

- ¿El modelo encuentra solución óptima? Reporte el **valor objetivo óptimo** obtenido y la cantidad de servidores activados.
- ¿Cuánto tiempo tarda Gurobi en resolver el modelo? Reporte el **tiempo de resolución** (en segundos).
- Experimente con **distintos tamaños de instancia** (aumente S y/o M progresivamente). ¿En qué punto Gurobi comienza a mostrar dificultades (tiempo excesivo, gap grande, infactibilidad, etc.)? Describa sus observaciones.
- Presente una **tabla o gráfico** que resuma los resultados de sus experimentos (tamaño de instancia vs. tiempo de resolución y/o gap).

## Entregables

### 1. Informe (PDF)

Estructura mínima requerida:

- **Portada:** nombre del curso, número de tarea, integrantes, fecha.
- **Índice**
- **Introducción:** descripción del problema y motivación.
- **Objetivos:** general y secundarios.
- **Desarrollo:** formulación completa del modelo MILP (variables, función objetivo, restricciones).
- **Resultados:** solución óptima, valor objetivo, variables de decisión relevantes, tiempos de ejecución, tabla/gráfico de experimentos.
- **Análisis de la solución:** interpretación de los resultados, ¿qué sucede al escalar las instancias?, ¿cuáles son los cuellos de botella del modelo?
- **Conclusiones**
- **Referencias** (si usaron fuentes adicionales)
- **Anexos** (si es necesario)

**Formalidades del informe** (se descuentan puntos por incumplimiento):

- Lenguaje técnico y formal, sin errores ortográficos.
- Texto justificado, fuente tamaño 12.

- Cada sección comienza en una nueva página.
- Cada imagen, gráfico o tabla debe tener **título y fuente** (si es de elaboración propia, indicarlo así).

Se recomienda revisar el informe antes de entregarlo. Esta vez sí se descontarán puntos por formalidades.

---

## 2. Cuaderno Jupyter (.ipynb)

El código debe estar bien estructurado e incluir:

- Generación de la instancia aleatoria (con semilla fija).
- Creación del modelo con **gurobipy**: variables, restricciones y función objetivo.
- Resolución del modelo y extracción de resultados.
- Código para los experimentos de escalabilidad.
- Tabla o gráfico de resultados.
- **Comentarios** explicativos en cada sección del código.

---

**Formato de entrega:** comprima el informe y el notebook en un único archivo .zip o .rar con el nombre **Tarea3\_GrupoN** (reemplace N por el número de su grupo). **No entregue los archivos por separado.**

---

## Plazos y Evaluación

- **Plazo de entrega:** Domingo 26 de abril, 23:59.
- **Grupos:** de 2 a 3 integrantes (**se recomienda 3**).
- **Inscripción:** anótense en los grupos de Canvas (Personas → Grupos → Tarea 3 - Grupo n), incluso si trabajan solos.

## Criterios de Evaluación

| Criterio                              | Ponderación |
|---------------------------------------|-------------|
| Formulación del modelo (Parte A)      | 40%         |
| Código y resultados (Parte B)         | 30%         |
| Informe y análisis de la solución     | 20%         |
| Calidad del análisis de escalabilidad | 10%         |

---

## Notas Importantes

- Asegúrense de que el modelo sea **factible** para la instancia base antes de escalar.
- Recuerden fijar la **semilla aleatoria** en el código para asegurar reproducibilidad.
- En el informe y en el código deben figurar los **nombres de todos los integrantes**.
- **Deben usar gurobipy** para la implementación del modelo.
- **Recomiendo** usen funciones para la generación de datos. De esta manera, pueden crear varias celdas simplemente cambiando los parámetros de la función.

Si tienen dudas, no duden en consultar. Pueden escribir al correo [vramireza@udd.cl](mailto:vramireza@udd.cl) o por mensaje al +56 9 9912 1814 (respondo siempre que puedo, dentro de horarios razonables).

```
import gurobipy as gp
from gurobipy import GRB
import numpy as np
```